

Giới thiệu về thuật toán SHAP

Nguyễn Phúc Thịnh và Nguyễn Đình Vinh


Nothing in life is to be feared, it is only to be understood.
Now is the time to understand more, so that we may fear less.

— Marie Curie

I. Giới thiệu

Con người chúng ta luôn sợ hãi những điều bản thân không biết. Trong lĩnh vực học máy, nỗi sợ về những điều không thể lý giải cũng hiện hữu tương tự. Các mô hình học máy, đặc biệt là các mô hình học sâu, thường được ví như những “black boxes” (tạm dịch: hộp đen). Chúng có thể đưa ra những dự đoán với độ chính xác đáng kinh ngạc, nhưng chúng ta lại không thể hiểu rõ cơ sở hay logic đằng sau những quyết định đó. Tại sao một mô hình lại từ chối đơn xin vay vốn của một khách hàng? Dựa vào những đặc điểm nào mà một hệ thống chẩn đoán y tế lại kết luận một khối u là ác tính?

Sự thiếu minh bạch này tạo ra những rủi ro lớn, từ việc gây ra sự thiếu tin tưởng, những quyết định sai lệch, bias (tạm dịch: thiên vị) cho đến các vấn đề pháp lý và đạo đức. Ở quy mô nhỏ hơn, việc không thể hiểu một mô hình học máy cũng dẫn đến việc chúng ta không thể tối ưu mô hình một cách tốt nhất mà chỉ có thể thử và sai. Đây chính là lúc eXplainable AI - XAI (tạm dịch: trí tuệ nhân tạo có thể giải thích được) vào cuộc.




Hình 1: Làm sao chúng ta biết mô hình phân loại của ta hợp với logic? Ở đây ta thấy rằng chó nhà được phân biệt với chó sói qua dây xích cổ, mô hình đáng tin ở trường hợp này.

XAI là một tập hợp các kỹ thuật và phương pháp giúp con người có thể hiểu và tin tưởng vào kết quả do các mô hình học máy tạo ra. Thay vì chỉ nhận được câu trả lời cuối cùng, XAI giúp

chúng ta “nhìn” vào bên trong hộp đen, lý giải tại sao mô hình lại đưa ra quyết định như vậy. Điều này không chỉ giúp các nhà nghiên cứu và người xây dựng các mô hình AI tối ưu tốt hơn, mà còn mang lại sự minh bạch và trách nhiệm, giúp con người tự tin hơn khi ứng dụng AI vào các lĩnh vực quan trọng như y tế, tài chính và pháp luật. Nói một cách đơn giản, XAI biến nỗi sợ về những điều không chắc chắn thành sự tin tưởng dựa trên sự thấu hiểu.

Để trả lời câu hỏi “Tại sao mô hình lại đưa ra dự đoán như vậy?”, có rất nhiều phương pháp XAI đã được phát triển. Trong số đó, SHAP (SHapley Additive exPlanations) nổi lên như một trong những cách tiếp cận mạnh mẽ và đáng tin cậy nhất. Dựa trên khái niệm Game Theory (tạm dịch: lý thuyết trò chơi) và Shapley Values (tạm dịch: giá trị Shapley), SHAP cung cấp một phương pháp nhất quán để tính toán mức độ đóng góp của từng đặc trưng vào kết quả dự đoán của mô hình đối với một điểm dữ liệu cụ thể.



Hình 2: SHAP là một trong những framework XAI được phát triển dựa trên nhiều nhất kế bên LIME.

Không giống như một số phương pháp chỉ cho biết đặc trưng nào là quan trọng một cách tổng thể, SHAP có khả năng giải thích chi tiết cho từng dự đoán riêng lẻ. Nó cho chúng ta biết đặc trưng nào đã “đẩy” dự đoán của mô hình tăng lên và đặc trưng nào đã “kéo” dự đoán xuống. Chính nhờ khả năng giải thích ở cấp độ cá thể này mà SHAP trở thành một công cụ vô giá để gỡ lỗi (debug) mô hình, phát hiện thiên vị và xây dựng niềm tin đối với người sử dụng mô hình. Trong viết này, chúng ta sẽ tìm hiểu về cách hoạt động của SHAP và các sử dụng thư viện nêu trên.

Bảng ký hiệu toán học. Để tiện theo dõi, bảng dưới đây tổng hợp một số ký hiệu sử dụng xuyên suốt bài viết này:

Bảng Ký hiệu Toán học

Ký hiệu	Ý nghĩa
N	Tổng số người chơi (trong lý thuyết trò chơi) hoặc tổng số đặc trưng (trong học máy).
S	Một liên minh (coalition), tức là một tập hợp con các đặc trưng.
$ S $	Kích thước của liên minh S , tức số đặc trưng trong liên minh đó.
$v(S)$	Hàm đặc trưng (characteristic function), đại diện cho đầu ra của mô hình khi chỉ sử dụng các đặc trưng trong liên minh S .
$\varphi_i(v)$	Giá trị Shapley của người chơi (hoặc đặc trưng) i .
$f(x)$	Mô hình hộp đen (black-box model) gốc cần được giải thích.
$g(x')$	Mô hình giải thích tuyến tính, dùng để xấp xỉ mô hình $f(x)$ một cách cục bộ.
x'	Vector nhị phân biểu diễn sự “có mặt” (1) hay “vắng mặt” (0) của một đặc trưng.
φ_i	Giá trị SHAP của đặc trưng thứ i , đo lường đóng góp của đặc trưng đó vào dự đoán.
φ_0	Giá trị cơ sở (base value), là dự đoán trung bình của mô hình trên toàn bộ tập dữ liệu nền.
$E[f(x)]$	Giá trị kỳ vọng của đầu ra mô hình, được dùng làm giá trị cơ sở φ_0 .
B	Tập dữ liệu nền (background dataset), thường được lấy mẫu từ tập huấn luyện.
Z	Một mẫu dữ liệu “lai” được tạo ra bằng cách kết hợp giá trị từ mẫu gốc và tập nền.
w_C	Trọng số của hạt nhân Shapley (Shapley kernel) gán cho một liên minh C .

Bảng thuật ngữ

Thuật ngữ	Ý nghĩa
Lý thuyết trò chơi	Nền tảng toán học được SHAP sử dụng để phân chia một cách công bằng “đóng góp” của từng đặc trưng vào kết quả dự đoán của mô hình.
Trò chơi hợp tác	Một kịch bản trong đó các “người chơi” (tức các đặc trưng) phải phối hợp với nhau trong các “liên minh” để tạo ra một giá trị chung (tức dự đoán của mô hình).
Giá trị Shapley	Một giá trị duy nhất, đại diện cho đóng góp trung bình của một đặc trưng qua tất cả các liên minh có thể có. Đây là cốt lõi của giá trị SHAP.
Mô hình hộp đen	Các mô hình học máy phức tạp (ví dụ: mạng nơ-ron, gradient boosting) mà cơ chế ra quyết định bên trong rất khó hoặc không thể hiểu được trực tiếp.
Tính diễn dịch	(Interpretability) Khả năng một mô hình vốn đã minh bạch và dễ hiểu (ví dụ: cây quyết định), không cần một công cụ giải thích bên ngoài.
Tính giải thích	(Explainability) Việc sử dụng các kỹ thuật hậu kiểm (post-hoc) như SHAP để tạo ra lời giải thích cho các mô hình hộp đen.
Tính trung thực	(Fidelity) Mức độ mà một lời giải thích phản ánh đúng logic ra quyết định thực sự của mô hình.
Giá trị cơ sở	Dự đoán trung bình của mô hình trên tập dữ liệu nền ($E[f(x)]$). Đây là điểm bắt đầu của mọi mô hình khi dự đoán. Cơ sở ở đây mang nghĩa “tập dữ liệu mô hình được huấn luyện dựa trên”.
Đóng góp cận biên	Sự thay đổi trong dự đoán của mô hình khi một đặc trưng được thêm vào một liên minh đã có. Giá trị Shapley là trung bình của tất cả các đóng góp cận biên.

Mục lục

I.	Giới thiệu	1
II.	Nội dung chính	6
II.1.	Các khái niệm trong XAI	6
II.2.	Giới thiệu thuật toán SHAP	8
II.3.	Phương pháp giải thích cộng tính và Kernel SHAP	11
II.4.	Tổng quan thuật toán SHAP	18
II.5.	Ví dụ tính toán Kernel SHAP từng bước	19
III.	Câu hỏi trắc nghiệm	22
IV.	Tài liệu tham khảo	25
	Phụ lục	25


II. Nội dung chính

II.1. Các khái niệm trong XAI

Để bắt đầu hành trình tìm hiểu và sử dụng XAI, chúng ta cần phân biệt rõ ba khái niệm chính của các nghiên cứu XAI nói chung: Interpretability (tạm dịch: tính diễn dịch), Explainability (tạm dịch: tính giải thích) và Fidelity (tạm dịch: tính trung thực). Việc hiểu các thuật ngữ trên có thể giúp ta biết khi nào nên áp dụng phương pháp nào và đưa ra những kết luận tin cậy mà ta cần.


Trước tiên ta sẽ đến với hai cặp thuật ngữ chính thường bị nhầm lẫn trong XAI là tính diễn dịch và tính giải thích. Nhiều người thường dùng hai thuật ngữ này thay thế cho nhau, nhưng chúng lại mô tả hai cách tiếp cận rất khác nhau để hiểu mô hình.

Tính diễn dịch (hay còn gọi là tính thông dịch) là khả năng con người có thể hiểu được cách một mô hình đưa ra quyết định **một cách tự nhiên** mà không cần một công cụ giải thích phụ trợ. Những mô hình có tính diễn dịch cao thường được ví như những **hộp kính** (**glass-box models**) hoặc **white-box models**). Chúng ta có thể “nhìn” thẳng vào cơ chế bên trong và hiểu được mối quan hệ nhân-quả giữa đầu vào và đầu ra. Ví dụ điển hình là mô hình cây quyết định (Decision Tree). Bằng cách đi theo các nhánh của cây, bất kỳ ai cũng có thể hiểu được tại sao một quyết định cụ thể được đưa ra.



Hình 3: Một mô hình cây quyết định. Ta quan sát thấy quyết định ‘Yes’ được đưa ra khi Outlook=Sunny và Humidity=Normal.

Mặt khác, **tính giải thích** thường được áp dụng cho các mô hình **hộp đen** (**black-box models**) như mạng nơ-ron học sâu hoặc các mô hình ensemble phức tạp. Bản thân các mô hình này quá phức tạp để con người có thể diễn dịch trực tiếp. Do đó, chúng ta cần các phương pháp **post-hoc** (tạm dịch: hậu kiểm) để tạo ra một lời giải thích gần đúng về hành vi của mô hình. Tính giải thích là việc xây dựng một “người phiên dịch” đứng giữa mô hình hộp đen và con người. SHAP và LIME là những ví dụ kinh điển của kỹ thuật này.




Hình 4: Tính giải thích hoạt động như một lớp diễn giải bên ngoài mô hình hộp đen, cung cấp lý do cho một quyết định cụ thể. Các phương pháp/mô hình hậu kiểm thường sẽ cho lời giải thích từ dữ liệu đầu vào thay vì sử dụng thông tin nội tại của mô hình.

Bảng dưới đây tóm tắt sự khác biệt cốt lõi giữa hai khái niệm được nhắc tới ở trên.

Tính diễn dịch (Interpretability)	Tính giải thích (Explainability)
Mô hình vốn minh bạch và dễ hiểu (hộp kính).	Áp dụng cho các mô hình phức tạp (hộp đen).
Hiểu được toàn bộ logic của mô hình.	Chỉ giải thích được hành vi cho một hoặc một nhóm dự đoán cụ thể.
Là một thuộc tính nội tại của mô hình.	Là một kỹ thuật hậu kiểm, áp dụng sau khi mô hình đã được huấn luyện.
Ví dụ: Linear Regression, Decision Trees, Logistic Regression.	Ví dụ: SHAP, LIME, LRP áp dụng cho Neural Networks, Gradient Boosting.

Bảng 1: So sánh giữa tính diễn dịch và tính giải thích.

Thuộc tính còn lại là khái niệm cực kỳ quan trọng để đánh giá chất lượng của một phương pháp giải thích. **Tính trung thực** (còn gọi là fidelity) đo lường mức độ mà một lời giải thích **phản ánh đúng** cơ chế ra quyết định thực sự của mô hình.



Hình 5: Minh họa tính trung thực. Lời giải thích tuy dễ hiểu (và hợp khoa học hơn), nhưng lại không đúng những gì mô hình đang suy nghĩ.

Hãy tưởng tượng một lời giải thích rất đơn giản và dễ hiểu, nhưng nó lại hoàn toàn sai lệch so với logic mà mô hình hộp đen đang sử dụng. Lời giải thích đó không những vô dụng mà còn nguy hiểm cho chúng ta vì nó tạo ra một niềm tin sai lầm đối với mô hình. Một phương pháp giải thích có độ trung thực cao sẽ tạo ra những lý giải gần nhất với sự thật về cách mô hình hoạt động. Ví dụ, nếu mô hình phân loại chó sói và husky dựa vào trong bức ảnh đó có tuyết không, một lời giải thích trung thực phải chỉ ra được “tuyết” là yếu tố quyết định, thay vì các đặc điểm hình thái của con vật.

Việc cân bằng giữa sự đơn giản của lời giải thích và độ trung thực của nó là một trong những thách thức lớn nhất trong lĩnh vực XAI.

II.2. Giới thiệu thuật toán SHAP

Sau khi đã nắm vững các khái niệm nền tảng, một câu hỏi tự nhiên được đặt ra: “Làm thế nào để chúng ta tìm được một phương pháp vừa có **tính giải thích** mạnh mẽ cho các mô hình hộp đen, lại vừa đảm bảo được **tính trung thực** ở mức cao nhất?”

Trong vô số các kỹ thuật XAI đã được phát triển, phương pháp **SHAP (SHapley Additive exPlanations)** là một trong những phương pháp được sử dụng nhiều nhất. SHAP không chỉ là một thuật toán; nó là một framework hợp nhất dựa trên khái niệm **lý thuyết trò chơi** và **giá trị Shapley**. Chính nhờ nền tảng này mà SHAP có thể cung cấp những lời giải thích thỏa mãn các thuộc tính công bằng và nhất quán, đặc biệt là **tính chính xác cục bộ (local accuracy)**, đảm bảo rằng tổng đóng góp của các đặc trưng sẽ bằng đúng chênh lệch giữa dự đoán và giá trị cơ sở (sẽ giải thích ở sau). Điều này trực tiếp giải quyết yêu cầu về **tính trung thực** - bảo đảm rằng lời giải thích chúng ta nhận được phản ánh đúng những gì mô hình đang “suy nghĩ”.


II.2.1. Nền tảng của lý thuyết trò chơi

Để hiểu được cốt lõi của SHAP, chúng ta hãy bắt đầu với một bối cảnh giả định về startup công nghệ như sau. Giả sử startup này có 3 thành viên chủ chốt: An, Bình, và Châu. Lợi nhuận cuối cùng của công ty không chỉ là tổng lợi nhuận mỗi người tự làm ra, mà còn phụ thuộc vào sự phối hợp của họ. Đây chính là bản chất của một **trò chơi hợp tác**.

Trong lý thuyết trò chơi, chúng ta định nghĩa các khái niệm sau:

- **Người chơi (Players)**: Các thành viên tham gia. Trong ví dụ này là {An, Bình, Châu}.
- **Liên minh (Coalition)**, ký hiệu là S : Một tập hợp con bất kỳ của những người chơi. Ví dụ, liên minh chỉ có An và Bình là $S = \{\text{An, Bình}\}$.
- **Hàm đặc trưng (Characteristic Function)**, ký hiệu là $v(S)$: Giá trị (lợi nhuận, kết quả) mà một liên minh S có thể tạo ra. Ví dụ, $v(\{\text{An, Bình}\})$ là lợi nhuận mà An và Bình tạo ra khi làm việc cùng nhau.

Vấn đề cốt lõi được đặt ra là: “Làm thế nào để phân chia tổng lợi nhuận $v(\{\text{An, Bình, Châu}\})$ một cách **công bằng** cho từng thành viên?” Việc chia đều là không hợp lý, vì chắc chắn mỗi người có đóng góp khác nhau. Đây chính là bài toán mà giá trị Shapley giải quyết.



Hình 6: Sự hợp tác giữa các thành viên tạo ra giá trị tổng thể. Đôi khi, sự kết hợp (liên minh) tạo ra giá trị lớn hơn tổng các phần riêng lẻ (hiệu ứng cộng hưởng - *synergy*).

II.2.2. Marginal contribution (tạm dịch: đóng góp cận biên)


Một cách tư duy trực quan khác để hiểu về sự đóng góp là hãy tưởng tượng các thành viên không tham gia vào một “liên minh” có sẵn, mà họ lần lượt xuất hiện để tạo nên một đội hoàn chỉnh. Người đến đầu tiên sẽ đóng góp toàn bộ giá trị cá nhân của họ. Người đến thứ hai sẽ đóng góp phần giá trị gia tăng mà họ tạo ra *dựa trên* sự có mặt của người đầu tiên. Rõ ràng, giá trị đóng góp của cùng một người sẽ rất khác nhau nếu họ là người tiên phong so với khi họ là mảnh ghép cuối cùng. Khái niệm này, được gọi là **đóng góp cận biên**, đo lường chính xác sự gia tăng giá trị này tại một thời điểm cụ thể.

Ví dụ, để tính đóng góp của Châu cho liên minh {An, Bình}, ta tính:

$$\Delta v = v(\{\text{An, Bình, Châu}\}) - v(\{\text{An, Bình}\})$$

Câu hỏi đặt ra cho chúng ta là: Ta có thể nói người màu xám chỉ đóng góp 3 đơn vị trong mọi trường hợp không? Có câu trả lời dứt khoát là **Không**. Chúng ta không thể kết luận vội vàng về giá trị của một thành viên chỉ dựa trên một bối cảnh duy nhất.

Vậy, con số nào mới thực sự đại diện cho “giá trị” công bằng của Châu? Một phương pháp giải thích đáng tin cậy không thể đưa ra những kết quả khác nhau cho cùng một đặc trưng chỉ vì chúng ta thay đổi thứ tự đánh giá. Chúng ta cần một giá trị duy nhất, tổng hợp, và công bằng, phản ánh được đóng góp của Châu trên *tất cả các kịch bản có thể xảy ra*.



Hình 7: Đóng góp của một thành viên (người màu xám) được tính bằng chênh lệch giá trị của liên minh trước và sau khi họ tham gia. Tuy nhiên, giá trị này không cố định mà thay đổi theo từng liên minh.

Tuy nhiên, cách tính này có một điểm yếu lớn: giá trị đóng góp của một người phụ thuộc rất nhiều vào **bối cảnh**, tức là họ tham gia vào liên minh nào. Đóng góp của Châu khi tham gia vào nhóm chỉ có An có thể rất khác so với khi tham gia vào nhóm đã có cả An và Bình.

Vấn đề cốt lõi ở đây là **sự phụ thuộc vào thứ tự (order dependency)**. Giá trị đóng góp mà chúng ta tính được cho một thành viên bị phụ thuộc hoàn toàn vào “kịch bản” hay “thứ tự hoán vị” (permutation) mà chúng ta đang xét. Nếu chúng ta tính đóng góp của Châu khi tham gia vào nhóm rỗng $\emptyset$, giá trị sẽ là $v(\{\text{Châu}\})$. Nếu Châu tham gia cuối cùng, giá trị lại là $v(\{\text{An}, \text{Bình}, \text{Châu}\}) - v(\{\text{An}, \text{Bình}\})$. Cả hai đều là những đóng góp cận biên hợp lệ, nhưng chúng lại đưa ra những con số rất khác nhau.

II.2.3. Giá trị Shapley

Năm 1953, nhà toán học đoạt giải Nobel Lloyd Shapley đã đề xuất một giải pháp để giải quyết vấn đề nói trên: để có được sự phân chia công bằng, chúng ta phải tính đến đóng góp cận biên của một người chơi trong *tất cả các liên minh có thể có* mà họ có thể tham gia, sau đó lấy trung bình có trọng số của các đóng góp này. Đây chính là **giá trị Shapley**.

Công thức tính giá trị Shapley cho người chơi i là:

$$\varphi_i(v) = \sum_{S \subseteq N \setminus \{i\}} \frac{|S|!(|N| - |S| - 1)!}{|N|!} [v(S \cup \{i\}) - v(S)]$$

Trong đó:

- $\varphi_i(v)$ là giá trị Shapley (đóng góp công bằng) của người chơi i .
- N là tập hợp tất cả người chơi.
- S là một liên minh không chứa người chơi i .
- $v(S \cup \{i\}) - v(S)$ chính là đóng góp cận biên của i khi tham gia vào liên minh S .
- Phần phân số $\frac{|S|!(|N| - |S| - 1)!}{|N|!}$ là trọng số, đại diện cho tất cả các thứ tự hoán vị mà liên minh S có thể hình thành trước khi i tham gia.

Nói một cách đơn giản, giá trị Shapley là **trung bình của tất cả các đóng góp cận biên có thể có** của một người chơi.

II.2.4. Từ Giá Trị Shapley đến SHAP trong Machine Learning

Framework SHAP áp dụng trực tiếp ý tưởng của giá trị Shapley vào việc giải thích các mô hình học máy. Sự tương ứng được thiết lập như sau:


- **Người chơi** → **Các đặc trưng (features)** của tập dữ liệu.
- **Trò chơi** → Việc đưa ra một **dự đoán duy nhất** cho một điểm dữ liệu cụ thể.
- **Hàm đặc trưng** $v(S)$ → **Đầu ra của mô hình** khi chỉ sử dụng tập hợp các đặc trưng trong liên minh S .
- **Giá trị Shapley** φ_i → **Giá trị SHAP** của đặc trưng i . Nó cho biết đặc trưng i đã đóng góp bao nhiêu vào việc dịch chuyển dự đoán của mô hình đi từ giá trị cơ sở (trung bình dự đoán trên toàn bộ tập dữ liệu) đến giá trị dự đoán cuối cùng cho điểm dữ liệu đó.

Một câu hỏi quan trọng là: “Làm thế nào mô hình có thể đưa ra dự đoán chỉ với một tập con các đặc trưng?” Các thuật toán SHAP hiện đại sử dụng các kỹ thuật xấp xỉ, chẳng hạn như thay thế các đặc trưng còn thiếu bằng các giá trị đại diện từ tập dữ liệu, để mô phỏng hiệu quả việc loại bỏ đặc trưng ra khỏi mô hình.

II.3. Phương pháp giải thích cộng tính và Kernel SHAP

Sau khi đã hiểu nền tảng lý thuyết của giá trị Shapley, chúng ta đối mặt với một rào cản lớn: tính toán. Việc tính toán giá trị Shapley chính xác đòi hỏi phải duyệt qua **tất cả các liên minh** có thể có của các đặc trưng. Điều này là bất khả thi trong thực tế. Hình bên thể hiện cách tính độ quan trọng của node xanh nước biển, với mỗi cặp hình là liên minh trước và sau khi loại bỏ node đó.

Chính vì thách thức này, chúng ta cần một phương pháp xấp xỉ hiệu quả. Kernel SHAP ra đời để giải quyết bài toán này, dựa trên một ý tưởng thuộc họ các **Additive Feature Attribution Methods - AFAMs** (tạm dịch: phương pháp gán đặc trưng cộng tính).




$$n = 4 \rightarrow 4 \times 2^4 = 64 \text{ times}$$

$$n = 32 \rightarrow 32 \times 2^{32} = 17.1 \text{ billions times}$$

Hình 8: Chi phí tính toán của giá trị Shapley bùng nổ theo tổ hợp. Với chỉ 32 đặc trưng, số lượng liên minh cần xét đã lên đến hàng tỷ, khiến việc chạy mô hình lặp đi lặp lại là không thể.

II.3.1. Mô hình giải thích cộng tính

Ý tưởng cốt lõi của AFAMs là xấp xỉ một mô hình hộp đen phức tạp $f(x)$ bằng một mô hình giải thích đơn giản hơn, có thể diễn giải được $g(x')$. Dạng mô hình đơn giản nhất mà con người có thể hiểu là mô hình tuyến tính.



Hình 9: Mô hình giải thích $g(x')$ là một xấp xỉ cục bộ của mô hình hộp đen $f(x)$. “Cộng tính” có nghĩa là đóng góp của mỗi đặc trưng được cộng lại để tạo thành dự đoán cuối cùng.

Như được minh họa trong công thức trên, các thành phần của mô hình giải thích được định nghĩa như sau:

- $g(x')$ là đầu ra của mô hình giải thích.
- x' là một vector nhị phân ($x'_i \in \{0, 1\}$) thể hiện sự “có mặt” (1) hay “vắng mặt” (0) của đặc trưng i .
- φ_0 là đầu ra của mô hình khi không có đặc trưng nào được đưa vào (giá trị cơ sở - *base value*).
- φ_i là **hiệu ứng (effect)** của đặc trưng i , chính là giá trị SHAP mà chúng ta cần tìm.

SHAP đảm bảo rằng các giá trị φ_i này chính là các giá trị Shapley, mang lại cho mô hình giải thích các thuộc tính lý thuyết mong muốn như **tính chính xác cục bộ**. Vấn đề bây giờ chúng ta phải giải quyết là: Làm thế nào để tìm ra các giá trị φ_i này một cách hiệu quả?

II.3.2. Kernel SHAP: hướng tiếp cận dựa trên hồi quy tuyến tính

Kernel SHAP là một thuật toán model-agnostic (tạm dịch: không phụ thuộc vào mô hình) thuộc họ LIME (Local Interpretable Model-agnostic Explanations). Nó biến bài toán tìm giá trị Shapley thành một bài toán **hồi quy tuyến tính có trọng số (weighted linear regression)**. Với cách biến đổi này, ta sẽ có thể tìm được giá trị Shapley cho từng thuộc tính thông qua cách huấn luyện mô hình hồi quy tuyến tính có trọng số. Quy trình hoạt động của Kernel SHAP như sau:

0. Xác định giá trị cơ sở (baseline value): Trước khi có thể đo lường đóng góp của từng đặc trưng, chúng ta cần một điểm xuất phát. Đây được gọi là **giá trị cơ sở (base value)**, ký hiệu là φ_0 . Giá trị này đại diện cho dự đoán trung bình của mô hình trên toàn bộ tập dữ liệu, hay nói cách khác, là dự đoán của mô hình khi nó “không có thông tin” về bất kỳ đặc trưng nào của điểm dữ liệu cụ thể mà chúng ta đang giải thích.

Cách tính giá trị cơ sở có thể được thực hiện qua 3 bước trực quan như sau:


1. Lấy một phần của tập dữ liệu train và gọi nó là **tập dữ liệu nền (background dataset)** B .

2. Tính giá trị kỳ vọng (thường là giá trị trung bình) cho từng cột đặc trưng. Kết quả là chúng ta có một vector duy nhất, $E[x_{bg}]$, đại diện cho một “mẫu dữ liệu trung bình”.
3. Đưa vector trung bình này vào mô hình hộp đen f để nhận được dự đoán. Dự đoán này chính là giá trị cơ sở φ_0 .

$$\varphi_0 = f(E[x_{bg}])$$

Giá trị này sẽ là mốc tham chiếu để ta có thể biết được mô hình của chúng ta bắt đầu điểm dự đoán từ đâu. Toàn bộ các giá trị SHAP (φ_i) mà chúng ta tính toán ở các bước sau sẽ giải thích cách chúng “đẩy” dự đoán của mô hình đi từ giá trị cơ sở φ_0 này đến dự đoán cuối cùng $f(x)$ cho điểm dữ liệu cụ thể.

1. Tạo dữ liệu huấn luyện cho mô hình đơn giản: Chúng ta không thể “loại bỏ” một đặc trưng khỏi mô hình rồi dùng mẫu dữ liệu được cắt bớt đó để đưa vào mô hình “hộp đen”. Việc này không được bởi vì khi ta bỏ trống một features, ta đã thực hiện việc giảm chiều đầu vào của dữ liệu. Thay vào đó, chúng ta mô phỏng sự vắng mặt của nó bằng cách thay thế giá trị của nó bằng các giá trị từ một tập dữ liệu nền.




Hình 10: Để mô phỏng các liên minh đặc trưng, chúng ta tạo ra các điểm dữ liệu mới bằng cách lấy mẫu các giá trị từ tập nền để thay thế cho các đặc trưng “vắng mặt”.

Quá trình tạo ra một điểm dữ liệu huấn luyện cho mô hình giải thích được minh họa chi tiết trong Hình 10. Ta bắt đầu với điểm dữ liệu gốc X cần giải thích (ví dụ: $[1.4, 2.3, \dots, 5.2]$) và một mẫu ngẫu nhiên từ **tập dữ liệu nền** B (ví dụ: $[1.0, 4.5, \dots, 3.2]$). Đầu tiên, một liên minh đặc trưng được lấy mẫu và biểu diễn dưới dạng một vector nhị phân Z' , chẳng hạn như $Z' = [0, 1, \dots, 0]$. Vector này đóng vai trò như một “mặt nạ”, quy định đặc trưng nào của dữ liệu gốc sẽ được giữ lại và đặc trưng nào sẽ bị thay thế. Dựa trên mặt nạ này, chúng ta xây dựng một điểm dữ liệu “lai” Z bằng cách lấy giá trị từ điểm gốc X tại các vị trí mà Z' bằng 1 (giữ lại

giá trị '2.3' ở vị trí thứ hai) và lấy giá trị từ tập nền B tại các vị trí mà Z' bằng 0 (thay thế bằng giá trị '1.0' ở vị trí đầu và '3.2' ở vị trí cuối). Điểm dữ liệu lai hoàn chỉnh $Z = [1.0, 2.3, \dots, 3.2]$ sau đó được đưa vào mô hình hộp đen f để thu về một dự đoán $f(Z)$.

Tại sao chúng ta lại cần vector nhị phân Z' ? Câu trả lời nằm ở mục tiêu cuối cùng của chúng ta: huấn luyện một **mô hình giải thích tuyến tính** g . Cặp giá trị $(Z', f(Z))$ vừa tạo ra chính là một mẫu huấn luyện, trong đó Z' là *dữ liệu đầu vào* và $f(Z)$ là *nhãn* (pseudo-label). Bằng cách lặp lại quy trình này nhiều lần, chúng ta tạo ra một tập dữ liệu để huấn luyện mô hình $g(Z') \approx f(Z)$. Vì g là mô hình tuyến tính, nó cần đầu vào đơn giản (vector nhị phân Z') để học ra các hệ số φ_i , chính là các giá trị SHAP mà chúng ta tìm kiếm.



Hình 11: Các đầu ra của mô hình hộp đen cho các liên minh được lấy mẫu sẽ được dùng làm nhãn giả (pseudo-label) để huấn luyện mô hình giải thích tuyến tính.

2. Shapley Kernel: trọng số cho mô hình: Một câu hỏi quan trọng được đặt ra: “Liệu mỗi mẫu dữ liệu giả lập này có quan trọng như nhau không?”. Câu trả lời là **Không**. Bởi vì chúng ta lấy mẫu ngẫu nhiên, và chỉ một phần của dữ liệu gốc, các trường hợp của mẫu dữ liệu ít xuất hiện hơn phải có trọng số cao hơn.

Lý thuyết Shapley chỉ ra rằng một số liên minh cung cấp nhiều thông tin hơn về đóng góp của một đặc trưng so với các liên minh khác. Cụ thể, các liên minh có rất ít đặc trưng (ví dụ, chỉ 1) hoặc có gần như đầy đủ các đặc trưng (ví dụ, $N - 1$) là quan trọng nhất. Kernel SHAP định nghĩa một hàm trọng số đặc biệt, gọi là **Shapley kernel**, để gán trọng số cao hơn cho các liên minh này.

Một câu hỏi có thể nảy sinh là tại sao chúng ta lại sử dụng tổ hợp (combination) để định nghĩa các liên minh mà không phải là chỉnh hợp (permutation). Lý do là vì giá trị Shapley không phụ thuộc vào thứ tự các đặc trưng xuất hiện trong một liên minh, mà chỉ quan tâm đến việc đặc trưng nào có mặt hoặc vắng mặt. Chỉnh hợp, vốn xem xét đến thứ tự, sẽ không phù hợp. Do đó, việc sử dụng tổ hợp là cách tiếp cận tự nhiên và chính xác trong bối cảnh này.

$$w_C = \frac{\# \text{ total features} - 1}{\# \text{ permutations of size } |C| \times \# \text{ included features in } C \times \# \text{ excluded features in } C}$$

The diagram shows the formula for w_C with three callouts:

- Green box:** Số lượng tổ hợp cùng kích thước (số features giữ lại) với mẫu đang xét. (Number of combinations of the same size (number of features kept) with the sample being considered.)
- Blue box:** Trong lý thuyết, nếu trường hợp chia cho 0 xảy ra, ta sẽ gán trọng số rất lớn cho mẫu đó. (In theory, if a division by 0 occurs, we will assign a very large weight to that sample.)
- Blue box:** Chúng ta loại bỏ hai trường hợp giữ lại toàn bộ features trong mẫu hoặc không có trường hợp nào trong mẫu (để tránh trường hợp chia cho 0). (We remove two cases: keeping all features in the sample or having no features in the sample (to avoid division by 0).)

Hình 12: Công thức trọng số của hạt nhân Shapley. Nó ưu tiên các liên minh có kích thước gần 0 hoặc gần N (tổng số đặc trưng), nơi mà đóng góp cận biên của một đặc trưng được thể hiện rõ nhất.

Công thức tính trọng số cho một liên minh C có $|C|$ đặc trưng là:

$$w_C = \frac{N - 1}{\binom{N}{|C|} \times |C| \times (N - |C|)}$$

Để hiểu sâu hơn về cấu trúc của công thức này, chúng ta có thể phân tách mẫu số của nó thành hai thành phần chính, mỗi thành phần mang một ý nghĩa riêng trong việc đảm bảo sự công bằng:

Thành phần thứ nhất: $\binom{N}{|C|}$ Đây là số lượng tổ hợp chập $|C|$ của N phần tử, tức là có tổng cộng bao nhiêu liên minh khác nhau có cùng kích thước $|C|$. Bằng cách đặt số hạng này ở mẫu số, chúng ta đang thực hiện một phép **chuẩn hóa dựa trên độ hiếm**. Các liên minh có kích thước rất nhỏ (ví dụ $|C| = 1$) hoặc rất lớn (ví dụ $|C| = N - 1$) có số lượng ít hơn nhiều so với các liên minh có kích thước ở khoảng giữa (ví dụ $|C| \approx N/2$). Do đó, việc chia cho $\binom{N}{|C|}$ sẽ gán một trọng số cao hơn cho các liên minh “hiếm” và quan trọng này, đúng như tinh thần của lý thuyết Shapley.


Thành phần thứ hai: $|C| \times (N - |C|)$ Thành phần này có thể được diễn giải từ góc độ lý thuyết hoán vị (permutation theory). Nó liên quan đến việc một đặc trưng cụ thể được thêm vào một liên minh tại một **ranh giới (boundary)** nhất định. Tích số này đạt giá trị nhỏ nhất khi $|C|$ gần 1 hoặc gần N , và đạt giá trị lớn nhất khi $|C|$ ở khoảng giữa. Việc đặt nó ở mẫu số cũng có tác dụng khuếch đại trọng số cho các liên minh ở hai cực (rất nhỏ hoặc rất lớn). Về mặt trực quan, thành phần này giúp điều chỉnh và “sửa lỗi” cho sự thay đổi đóng góp của một đặc trưng ngay tại thời điểm nó được thêm vào một liên minh.

Ví dụ về SHAP Kernal với số features bằng 5

Như đã nói ở trên, chúng ta sẽ không lấy mẫu hai trường hợp cạnh biên ở đây	K (số lượng features được giữ lại)	Kích thước tổ hợp	Trọng số của toàn bộ mẫu trong tổ hợp	
	1	5	$4/20 = 0.20$	$\frac{5-1}{\binom{5}{1} \times 1 \times 4} = \frac{4}{20}$
	2	10	$4/60 = 0.06$	
	3	10	$4/60 = 0.06$	$\frac{5-1}{\binom{5}{2} \times 2 \times 3} = \frac{4}{60}$
	4	5	$4/20 = 0.20$	

Hình 13: Ví dụ về trọng số của hạt nhân Shapley với 5 đặc trưng. Các liên minh có 1 hoặc 4 đặc trưng được gán trọng số cao nhất (0.20), trong khi các liên minh có 2 hoặc 3 đặc trưng có trọng số thấp hơn (0.06).

3. Huấn luyện mô hình: Sau khi đã có tập dữ liệu giả lập, nhân tương ứng (dự đoán của mô hình hộp đen) và trọng số (từ hạt nhân Shapley), chúng ta tiến hành huấn luyện một mô hình hồi quy tuyến tính có trọng số. Điều kỳ diệu nằm ở đây: Lundberg và Lee (2017) đã chứng minh rằng nếu chúng ta giải bài toán hồi quy có trọng số này, các hệ số φ_i tìm được chính là **giá trị Shapley duy nhất** thỏa mãn các thuộc tính mong muốn. Về bản chất, Kernel SHAP đã chuyển một bài toán tổ hợp phức tạp thành một bài toán hồi quy hiệu quả và dễ giải quyết.



Hình 14: Ta khớp một mô hình tuyến tính có trọng số vào dữ liệu được tạo ra từ mô hình hộp đen. Các hệ số hồi quy (slope) của mô hình tuyến tính này chính là các giá trị Shapley.

4. Đưa ra lời giải thích: Để trình bày những thông tin độ quan trọng của các thuộc tính một cách trực quan và dễ hiểu nhất, thư viện SHAP cung cấp **biểu đồ thác nước (Waterfall Plot)**. Sau khi đã lấy được trọng số Shapley xong, chúng ta cần đưa ra lời giải thích dễ hiểu cho người dùng. Lời giải thích mặc định đưa chia làm các phần chính sau: điểm bắt đầu dự đoán của mô hình, dự đoán của mô hình ở trường hợp đang xét, giá trị của các features, và ảnh hưởng của các features đó đến mô hình.

Biểu đồ bắt đầu từ **giá trị cơ sở** ($E[f(x)]$), thường được hiển thị ở dưới cùng của trục hoành. Sau đó, mỗi đặc trưng được thêm vào tuần tự, và giá trị SHAP tương ứng của nó sẽ “đẩy” hoặc “kéo” dự đoán:


- **Các thanh màu đỏ:** Đại diện cho các đặc trưng có giá trị SHAP dương, làm *tăng* giá trị dự đoán. Trong các bài toán multi label, thuật ngữ làm tăng giá trị dự đoán mang nghĩa làm tăng xác suất của lớp gốc trong mẫu dữ liệu đang xét. Ví dụ: chúng ta sử dụng ảnh con mèo trong tập dữ liệu ImageNet1k để đưa qua mô hình hộp đen, làm tăng giá trị dự đoán của ta ở đây là làm tăng $P(\text{Mèo})$ so với $P(\text{Toàn bộ các lớp còn lại})$.
- **Các thanh màu xanh:** Đại diện cho các đặc trưng có giá trị SHAP âm, làm *giảm* giá trị dự đoán.

Độ dài của mỗi thanh tỷ lệ thuận với độ lớn ảnh hưởng của đặc trưng đó. Quan trọng nhất, các đặc trưng thường được sắp xếp theo mức độ ảnh hưởng từ lớn nhất đến nhỏ nhất, giúp người dùng ngay lập tức xác định được những yếu tố then chốt nào đã quyết định kết quả dự đoán. Quá trình này tiếp diễn cho đến khi tất cả các đóng góp được cộng lại, và giá trị cuối cùng trên trục hoành chính là **dự đoán thực tế** của mô hình ($f(x)$) cho điểm dữ liệu đó.

Lưu ý

Tuy các thuộc tính được sắp xếp từ trên xuống theo độ quan trọng, nhưng ta phải đọc cách mô hình đưa ra quyết định từ dưới lên. Như trong hình minh họa bên dưới, các thuộc tính sẽ được thêm tuần tự từ “ít đóng góp nhất” đến “đóng góp nhiều nhất”, nếu ta đổi thứ tự đóng góp của các thuộc tính, giá trị Shapley của chúng có thể thay đổi.


Nhờ vậy, biểu đồ thác nước không chỉ cho biết đặc trưng nào quan trọng, mà còn định lượng chính xác từng đóng góp và cho thấy quá trình “suy luận” của mô hình một cách minh bạch.




Hình 15: Biểu đồ thác nước SHAP cho một dự đoán cụ thể. Biểu đồ bắt đầu từ giá trị cơ sở $E[f(x)] = 6.47$ (với khung xanh). Mỗi thanh tiếp theo biểu diễn giá trị SHAP của một đặc trưng: thanh màu đỏ làm tăng dự đoán, trong khi thanh màu xanh làm giảm dự đoán. Sau khi cộng dồn tất cả các ảnh hưởng, ta thu được dự đoán cuối cùng của mô hình là $f(x) = 6.114$ (với khung màu đỏ).

II.4. Tổng quan thuật toán SHAP

Quy trình bắt đầu với một mô hình hộp đen đã được huấn luyện và một điểm dữ liệu X cụ thể mà chúng ta muốn giải thích. Để có một mốc so sánh, thuật toán cần một tập dữ liệu nền, thường được lấy mẫu ngẫu nhiên (ví dụ: 100 mẫu) từ chính tập huấn luyện. Tập nền này đại diện cho phân phối dữ liệu chung. Đồng thời, giá trị cơ sở φ_0 , tức là dự đoán trung bình của mô hình trên toàn bộ tập nền cũng được tính toán ở bước này.




Hình 16: Khởi tạo thuật toán: xác định mẫu cần giải thích X , lấy tập dữ liệu nền từ tập huấn luyện và tính toán giá trị cơ sở.



Hình 17: Tạo các mẫu dữ liệu "lai" bằng cách kết hợp giá trị từ X và tập nền, sau đó đưa qua mô hình hộp đen để lấy dự đoán.

Các mẫu lai phức tạp được chuyển đổi thành các vector nhị phân đơn giản, trong đó '1' đại diện cho sự hiện diện của đặc trưng từ mẫu gốc X , và '0' đại diện cho sự vắng mặt (được thay bằng giá trị từ tập nền). Các vector nhị phân này (đầu vào), cùng với các dự đoán thu được ở Bước 2 (nhân) và trọng số tương ứng, được sử dụng để huấn luyện một mô hình hồi quy tuyến tính có trọng số. Các hệ số $(\varphi_1, \varphi_2, \dots)$ của mô hình tuyến tính này chính là các giá trị SHAP mà chúng ta cần tìm.



Hình 18: Dữ liệu được đơn giản hóa thành dạng nhị phân và được dùng để huấn luyện một mô hình tuyến tính, từ đó suy ra các giá trị SHAP.

II.5. Ví dụ tính toán Kernel SHAP từng bước

Để thực sự hiểu rõ cách Kernel SHAP hoạt động, chúng ta sẽ cùng nhau thực hiện một ví dụ tính toán chi tiết như dựa trên các bước được nói ở trên với bộ dữ liệu dạng bảng đơn giản dưới đây.

Bối cảnh bài toán (Problem Setup)

Giả sử chúng ta có một mô hình hộp đen f đã được huấn luyện. Để đơn giản cho việc tính toán, mô hình này chỉ có 3 đặc trưng đầu vào $(F1, F2, F3)$ và được định nghĩa như sau:

$$f(F1, F2, F3) = 5 + 2 \times F1 + 3 \times F2 - F3$$

Điểm dữ liệu X cần giải thích	Tập dữ liệu nền (background set) B		
	F1	F2	F3
F1 F2 F3			
5 2 4	1	2	8
	3	0	6
	$E[X_{bg}] = 2 \quad E[X_{bg}] = 1 \quad E[X_{bg}] = 7$		

Bảng 2: Điểm dữ liệu X cần giải thích.

Bảng 3: Tập dữ liệu nền B và giá trị trung bình.

Các giá trị cần tính:

- **Giá trị cơ sở φ_0 :** là dự đoán của mô hình trên mẫu dữ liệu nền trung bình.

$$\varphi_0 = f(E[X_{bg}]) = f(2, 1, 7) = 5 + (2 \times 2) + (3 \times 1) - 7 = 5$$

- **Dự đoán cuối cùng $f(x)$:** là dự đoán của mô hình trên điểm dữ liệu X .

$$f(x) = f(5, 2, 4) = 5 + (2 \times 5) + (3 \times 2) - 4 = 17$$

II.5.1. Bước 1 và 2: Tạo hoán vị, lấy dự đoán và tính trọng số

Với 3 đặc trưng, chúng ta sẽ có $2^3 = 8$ liên minh (hoán vị) có thể có. Với mỗi liên minh, ta tạo một mẫu dữ liệu lai Z bằng cách kết hợp giá trị từ $X = (5, 2, 4)$ và $E[X_{bg}] = (2, 1, 7)$, sau đó tính dự đoán $F(Z)$ và trọng số W tương ứng.

ID	Liên minh	Vector nhị phân Z'	Mẫu lai Z	Dự đoán $F(Z)$	Trọng số W
Z0	{}	(0,0,0)	(2,1,7)	5	∞
Z1	{F1}	(1,0,0)	(5,1,7)	11	0.333
Z2	{F2}	(0,1,0)	(2,2,7)	8	0.333
Z3	{F3}	(0,0,1)	(2,1,4)	8	0.333
Z4	{F1, F2}	(1,1,0)	(5,2,7)	14	0.333
Z5	{F1, F3}	(1,0,1)	(5,1,4)	14	0.333
Z6	{F2, F3}	(0,1,1)	(2,2,4)	11	0.333
Z7	{F1, F2, F3}	(1,1,1)	(5,2,4)	17	∞

Bảng 4: Tập dữ liệu huấn luyện cho mô hình giải thích tuyến tính.

Cách tính trọng số: Trọng số W được tính bằng công thức Shapley Kernel. Ví dụ, với các liên minh có 1 đặc trưng ($|Z'| = 1$):

$$w = \frac{M - 1}{\binom{M}{|Z'|} \times |Z'| \times (M - |Z'|)} = \frac{3 - 1}{\binom{3}{1} \times 1 \times (3 - 1)} = \frac{2}{3 \times 1 \times 2} = \frac{2}{6} \approx 0.333$$

Các trường hợp $|Z'| = 0$ và $|Z'| = M$ có trọng số vô hạn (∞) để đảm bảo mô hình hồi quy tuyến tính luôn đi qua điểm bắt đầu và điểm kết thúc. Đây là cách ta đảm bảo mô hình của ta giống với mô hình gốc (nghĩa là ta xấp xỉ mô hình tuyến tính với mô hình hộp đen).

II.5.2. Bước 3: Huấn luyện mô hình giải thích và tìm giá trị SHAP

Bây giờ, chúng ta sử dụng các cột Z' , $F(Z)$ và W từ bảng trên để huấn luyện một mô hình hồi quy tuyến tính có trọng số (weighted linear regression).

$$F(Z) \approx g(Z') = \varphi_0 + \varphi_1 Z'_1 + \varphi_2 Z'_2 + \varphi_3 Z'_3$$

Kết quả giải bài toán hồi quy này (hoặc giải hệ phương trình) sẽ cho chúng ta các hệ số φ_i chính là giá trị SHAP:

$$\begin{aligned}\varphi_1(\text{cho F1}) &= 6.0 \\ \varphi_2(\text{cho F2}) &= 3.0 \\ \varphi_3(\text{cho F3}) &= 3.0\end{aligned}$$

Một thuộc tính quan trọng của SHAP là **tính cộng tính (additivity)**. Tổng của giá trị cơ sở và tất cả các giá trị SHAP phải bằng đúng dự đoán cuối cùng.

$$\varphi_0 + \varphi_1 + \varphi_2 + \varphi_3 = 5.0 + 6.0 + 3.0 + 3.0 = \mathbf{17.0}$$

Kết quả này khớp chính xác với giá trị $f(x) = 17$ mà chúng ta đã tính ban đầu. Nghĩa là mô hình của chúng ta đã giải thích được mô hình hộp đen từ bài toán và vẫn đảm bảo 3 tính chất của lớp mô hình “giải thích cộng tính”.

Lời giải thích cuối cùng cho người dùng là:

- Mô hình bắt đầu từ dự đoán trung bình là **5.0**.

- Đặc trưng **F1** (có giá trị là 5) đã có đóng góp **lớn nhất**, làm **tăng** dự đoán lên **6.0** đơn vị.
- Đặc trưng **F2** (có giá trị là 2) làm **tăng** dự đoán lên **3.0** đơn vị.
- Đặc trưng **F3** (có giá trị là 4) cũng làm **tăng** dự đoán lên **3.0** đơn vị.
- Tổng hợp lại, dự đoán cuối cùng là **17.0**.

III. Câu hỏi trắc nghiệm

1. Tại sao khái niệm “Tính trung thực” (Fidelity) lại cực kỳ quan trọng đối với một phương pháp giải thích như SHAP?
 - (a) Vì nó đảm bảo lời giải thích phải đơn giản và bất kỳ ai cũng có thể hiểu được.
 - (b) Vì nó đảm bảo lời giải thích phản ánh đúng logic và cơ chế ra quyết định thực sự của mô hình.
 - (c) Vì nó đảm bảo phương pháp giải thích có thể áp dụng cho mọi loại mô hình học máy.
 - (d) Vì nó giúp mô hình hộp đen ban đầu đạt được độ chính xác cao hơn sau khi được giải thích.
2. Sự khác biệt cơ bản nhất giữa một mô hình có “Tính diễn dịch” (Interpretability) và một mô hình cần “Tính giải thích” (Explainability) là gì?
 - (a) Mô hình diễn dịch luôn chính xác hơn mô hình cần giải thích.
 - (b) Mô hình diễn dịch vốn đã minh bạch (hộp kính), trong khi mô hình cần giải thích thường phức tạp (hộp đen).
 - (c) Mô hình diễn dịch chỉ dùng cho bài toán hồi quy, còn mô hình cần giải thích chỉ dùng cho bài toán phân loại.
 - (d) Mô hình diễn dịch không cần dữ liệu để huấn luyện, còn mô hình cần giải thích thì có.
3. Tại sao việc tính toán giá trị Shapley một cách chính xác lại là một thách thức lớn trong thực tế?
 - (a) Vì công thức toán học của giá trị Shapley quá phức tạp để lập trình.
 - (b) Vì nó đòi hỏi phải biết trước giá trị đóng góp chính xác của từng đặc trưng.
 - (c) Vì nó yêu cầu phải xét qua tất cả các liên minh (tổ hợp) đặc trưng có thể có, dẫn đến bùng nổ tổ hợp về mặt tính toán.
 - (d) Vì nó chỉ hoạt động với các mô hình tuyến tính, không áp dụng được cho các mô hình phức tạp.
4. Trong Kernel SHAP, mục đích của việc sử dụng một “tập dữ liệu nền” (background dataset) là gì?
 - (a) Để huấn luyện lại mô hình hộp đen từ đầu nhằm tăng độ chính xác.
 - (b) Để tính toán giá trị cơ sở (base value) và để mô phỏng sự “vắng mặt” của một đặc trưng.
 - (c) Để kiểm tra xem mô hình có bị overfitting hay không.
 - (d) Để tạo ra các đặc trưng mới (feature engineering) cho mô hình giải thích.
5. Theo bài viết, tại sao giá trị Shapley được coi là một cách phân chia “công bằng”?
 - (a) Vì nó luôn gán giá trị dương cho các đặc trưng quan trọng và giá trị âm cho các đặc trưng không quan trọng.
 - (b) Vì nó chia đều tổng đóng góp cho tất cả các đặc trưng.

- (c) Vì nó tính đến đóng góp của một đặc trưng trong mọi bối cảnh (liên minh) có thể có, rồi lấy trung bình.
- (d) Vì nó dựa trên một cuộc bỏ phiếu dân chủ giữa các chuyên gia.
6. Trong Waterfall Plot của SHAP, giá trị ở điểm cuối cùng (ví dụ: $f(x) = 6.114$) đại diện cho điều gì?
- (a) Dự đoán trung bình của mô hình trên toàn bộ tập dữ liệu.
- (b) Giá trị SHAP lớn nhất trong số tất cả các đặc trưng.
- (c) Dự đoán cuối cùng và thực tế của mô hình hộp đen cho điểm dữ liệu cụ thể đó.
- (d) Tổng độ lớn (giá trị tuyệt đối) của tất cả các giá trị SHAP.
7. Kernel SHAP biến bài toán tìm giá trị Shapley phức tạp thành một bài toán đơn giản hơn. Đó là bài toán gì?
- (a) Bài toán phân cụm (Clustering).
- (b) Bài toán cây quyết định (Decision Tree).
- (c) Bài toán tối ưu hóa mạng nơ-ron (Neural Network Optimization).
- (d) Bài toán hồi quy tuyến tính có trọng số (Weighted Linear Regression).
8. Mục đích của “SHAP Kernel” là gì?
- (a) Gán trọng số cao hơn cho các liên minh có kích thước trung bình (ví dụ, có $N/2$ đặc trưng).
- (b) Gán trọng số bằng nhau cho tất cả các liên minh để đảm bảo sự công bằng.
- (c) Gán trọng số cao hơn cho các liên minh có rất ít hoặc rất nhiều đặc trưng.
- (d) Chỉ chọn ra những liên minh quan trọng nhất và bỏ qua phần còn lại.
9. Quan sát bảng dữ liệu được tạo ra trong quá trình hoạt động của Kernel SHAP với tổng số 4 features ($M=4$). Dựa vào công thức của SHAP Kernel, hãy tính giá trị trọng số W cho các mẫu $Z1$ và $Z2$ (trường hợp liên minh chỉ có 1 feature, tức $|Z'| = 1$)?

Số lượng features bằng 4

ID	Z	Z'	W
Z0	(1,1,1,4)	(0,0,0,0)	?
Z1	(3,1,1,4)	(1,0,0,0)	?
Z2	(1,4,1,4)	(0,1,0,0)	?
...			...
Z15	(3,4,2,10)	(1,1,1,1)	?

- (a) 0.125
- (b) 0.25
- (c) ∞ (vô cùng)

(d) 1.0

10. Tiếp tục với bảng dữ liệu ở trên ($M=4$), giá trị trọng số W cho mẫu $Z0$ (liên minh rỗng, $|Z'| = 0$) và $Z15$ (liên minh đầy đủ, $|Z'| = 4$) là bao nhiêu theo lý thuyết, và tại sao chúng thường bị loại bỏ trong các thư viện lập trình?

(a) $W = 0$, vì chúng không cung cấp thông tin về sự tương tác giữa các feature.

(b) $W = 1$, vì chúng là các trường hợp cơ sở để so sánh.

(c) $W = \infty$ (vô cùng), vì mẫu số trong công thức bằng 0, và chúng bị loại bỏ để tránh lỗi tính toán.

(d) $W = 0.125$, vì chúng có độ quan trọng thấp nhất trong các liên minh.

IV. Tài liệu tham khảo

- [1] Q.-V. D. Truong-Binh Duong Phuc-Thinh Nguyen, *Web*, <https://aivietnam.edu.vn/>, 2025. [Online]. Available: <https://aivietnam.edu.vn/blog/step-by-step-XAI>.
- [2] P.-T. Nguyen, *Code image*, <https://aivietnam.edu.vn/>, 2025. [Online]. Available: https://drive.google.com/file/d/19v2QFjzxPhAhD8m23r-q_VC8urKRFq1b/view?usp=sharing.
- [3] P.-T. Nguyen, *Code tabular*, <https://aivietnam.edu.vn/>, 2025. [Online]. Available: https://drive.google.com/file/d/1ntLp-PpKc1Hrg9hzRys1iulaAfF_9Klj/view?usp=drive_link.
- [4] P.-T. Nguyen, *Code deepshap*, <https://aivietnam.edu.vn/>, 2025. [Online]. Available: https://drive.google.com/file/d/1MGkl_ZOE8csQWBydxNVZqjgrS1Dyomzm/view?usp=drive_link.

Phụ lục

1. **Code:** Các file code được đề cập trong bài có thể được tải tại đây.
2. **Q&A:** Bạn có thể đặt thêm câu hỏi về nội dung bài đọc trong group Facebook hỏi đáp tại đây. Tất cả câu hỏi sẽ được trả lời trong vòng 3-4 tiếng.

AIO_QAs-Verified

🔒 Private group · 1.4K members



Hình 19: Hình ảnh group facebook AIO Q&A.